PySpark Merkblatt-1/2

www.datamics.com

PySpark Grundlagen

PySpark ist eine Python-API für Apache Spark, ein leistungsstarkes open-source Framework für Cluster und Datenanalyse.

SparkContext initialisieren

```
from pyspark import SparkContext
sc = SparkContext(master = 'local[2]')
```

SparkContext Informationen

sc.version	Version
sc.pythonVer	Python Version
sc.master	Master URL
str(sc.sparkHome)	Pfad zu Spark auf den Nodes
str(sc.sparkUser())	Benutzername
sc.appName	Name der App
sc.applicationId	ID der App
sc.defaultParallelism	Parallelisierung
sc.defaultMinPartitions	Minimale Anzahl Partitionen für RDDs

Konfiguration

```
from pyspark import SparkConf, SparkContext

conf = (SparkConf()
         .setMaster("local")
        .setAppName("My app")
        .set("spark.executor.memory", "1g"))

sc = SparkContext(conf = conf)
```

PySpark Shell

PySpark hat eine eigene Shell, in der ein SparkContext **sc** bereits erzeugt ist:

```
./bin/spark-shell –master local[2]
./bin/pyspark –master local[4] –py-files code.py
```

Dabei wird der verwendete Master mit **–master** und Python-Scripte, EGG-, oder ZIP-Dateien als durch Kommas getrennte Dateinamen mit **–py-files** übergeben.

Daten laden

Externe Daten:

```
textFile = sc.textFile("/mein/ordner/*.txt")
textFile2 = sc.wholeTextFiles("/mein/ordner/")
```

Parallelisierte Verbindungen:

```
rdda = sc.parallelize([('a',7),('a',2),('b',2)])
rddb = sc.parallelize([('a',2),('d',1),('b',1)])
rddc = sc.parallelize(range(100))
```

Json:

```
df = spark.read.json('pfad/datei.json')
```

rdda-Informationen auslesen

Grundlagen

rdda.getNumPartitions() **3**	Anzahl Partitionen
rdda.count() **3**	Anzahl rdda Instanzen
rdda.countByKey() **defaultdict(<type 'int'>,'a':2,'b':1)**	Anzahl Instanzen nach Schlüssel
rdda.countByValue() **defaultdict(<type 'int'>,('b',2):1,('a',2):1,('a',7):1)**	Anzahl Instanzen nach Wert
rdda.collectAsMap() **'a': 2,'b': 2**	Instanzen als Dictionary
rddc.sum() **4950**	Summe der rdda-Elemente
sc.parallelize([]).isEmpty() **True**	Ist das rdda leer?

Gesamtwerte

rddc.max() **99**	Maximum
rddc.min() **0**	Minimum
rddc.mean() **49.5**	Mittelwert
rddc.stdev() **28.866070047722118**	Standardabweichung
rddc.variance() **833.25**	Varianz
rddc.histogram(3) **([0,33,66,99],[33,33,34])**	Histogramm mit 3 Bins
rddc.stats()	Alle obigen Gesamtwerte

Iterationen

Eine Funktion auf alle RDDs anwenden:

Funktion	Ausgabe
def g(x): print(x) **rdda.foreach(g)**	**('a', 7)** **('b', 2)** **('a', 2)**

Daten manipulieren

Funktionen anwenden

rdda.map(lambda x: x+(x[1],x[0])) **[('a',7,7,'a'),('a',2,2,'a'),('b',2,2,'b')]**	Funktion auf alle Elemente anwenden
rdd5 = rdda.flatMap(lambda x: x+(x[1],x[0])) **rdd5.collect()** **['a',7,7,'a','a',2,2,'a','b',2,2,'b']**	Auf alle Elemente anwenden und verflachen

Daten auswählen

rdda.collect() **[('a', 7), ('a', 2), ('b', 2)]**	Liste aller Elemente
rdda.first() **('a', 7)**	Erstes Element
rdda.take(n) **[('a', 7), ('a', 2)]**	Erste **n** Elemente
rdda.take(2) **[('b', 2), ('a', 7)]**	Beste zwei Elemente
rddc.sample(False, 0.15, 81).collect() **[3,4,27,31,40,41,42,43,60,76,79,80,86,97]**	Randomisierte Teilmenge
rdda.filter(lambda x: "a"in x).collect() **[('a',7),('a',2)]**	Filterfunktion anwenden
rdd5.distinct().collect() **['a',2,'b',7]**	Verschiedene Werte filtern

Mathematische Operationen

rdda.subtract(rddb).collect() **[('b',2),('a',7)]**	Jeder Wert von **rdda** der nicht in **rddb** ist
rdda.subtractByKey(rddb).collect() **[('d', 1)]**	(Schlüssel, Wert) für Schlüssel exklusiv in **rdda**
rdda.cartesian(rddb).collect()	Kartesisches Produkt von **rdda** und **rddb**

Weitere Themen

DataFrame aus RDD

```
df = rdd.map(lambda x: Row(**f(x))).toDF()
df = sqlContext.createDataFrame(rdd, schema)
```

Fehlende Werte

df.na.fill()	Alle **null**-Werte ersetzen
df.na.drop()	Alle Zeilen mit **null**-Werten löschen

Daten zusammenfügen

left.join(right,key, how='*')	* = left, right, inner, full

Filtern

df.filter(df["alter"]>24)	Nur Einträge mit **alter** größer 24 behalten

Sortieren

rddb.sortBy(lambda x: x[1]).collect() **[('d',1),('b',1),('a',2)]**	Sortierfunktion
rddb.sortByKey() **[('a',2),('b',1),('d',1)]**	Nach Schlüssel

Repartitionieren

rdda.repartition(4)	Neue rdda mit 4 Partitionen
rdda.coalesce(1)	Anzahl Partitionen auf 1 reduzieren

Speichern

```
rdda.saveAsTextFile("rdda.txt")
rdda.saveAsHadoopFile(
  "hdfs://nodehost/parent/child",
  'org.apache.hadoop.mapred.TextOutputFormat'
)
```

SparkContext beenden

```
sc.stop()
```

Ausführen

```
./bin/spark-submit \
examples/src/main/python/pi.py
```

DATAMICS
machine intelligence consulting services

PySpark Merkblatt-2/2

DataFrames zusammenfügen

Verändernde Joins

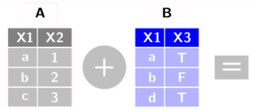

Zeilenweise von **B** nach **A**


```
A.join(B,'X1',how='left')
 .orderBy('X1',
 ascending=True).show()
```

Zeilenweise von **A** nach **B**


```
A.join(B,'X1',how='right')
 .orderBy('X1',
 ascending=True).show()
```

Nur gemeinsame Zeilen


```
A.join(B,'X1',how='inner')
 .orderBy('X1',
 ascending=True).show()
```

Alle Zeilen


```
A.join(B,'X1',how='full')
 .orderBy('X1',
 ascending=True).show()
```

Joins filtern

In **B** enthaltene **A** Zeilen


```
A.join(B,'X1',how='left_semi')
 .orderBy('X1',
 ascending=True).show()
```

In **B** nicht enthaltene **A** Zeilen


```
A.join(B,'X1',how='left_anti')
 .orderBy('X1',
 ascending=True).show()
```

DataFrame Operationen

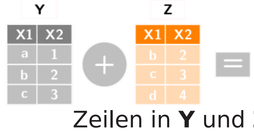

Zeilen in **Y** und **Z**


```
Y.intersect(Z).show()
```

Zeilen in **Y** und/oder **Z**

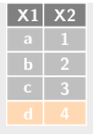


```
Y.union(Z).dropDuplicates()
 .orderBy('X1',
 ascending=True).show()
```

Zeilen nur in **Y**


```
Y.subtract(Z).show()
```

Daten bearbeiten

Verbinden

Z als neue Zeilen anbinden

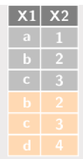


```
Y.union(Z) .orderBy('X1',
 ascending=True).show()
```

Z als neue Spalten anbinden

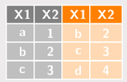


```
zipDataFrames(Y,Z).show()
```

Aufteilen

Zellen aufteilen


```
df.select("key", df.value[0], df.value[1], df.value[2]).show()
```

Spalten in Zeilen aufteilen

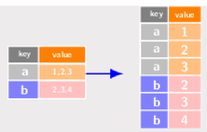


```
df.select("key",F.split("values", ",").alias("values"),
  F.posexplode(F.split("values",",")).alias("pos", "val")).drop("val")
  .select("key",F.expr("values[pos]").alias("val")).show()
```

Spalten in Zeilen überführen

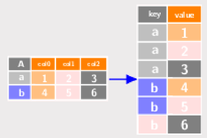


```
def to_long(df, by):
  cols, dtypes = zip(*((c,t) for (c, t) in df.dtypes if c not in by))
  kvs = explode(array([
    struct(lit(c).alias("key"), col(c).alias("val")) for c in cols
    ])).alias("kvs")
  return df.select(by + [kvs]).select(by + ["kvs.key", "kvs.val"])
```

Pivotieren

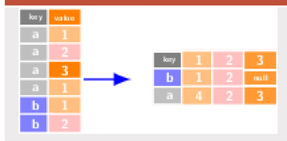


```
df.groupBy(['key']) .pivot('col1').sum('col1').show()
```

Gruppieren

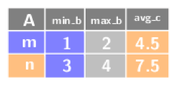


```
df.groupBy(['A'])
  .agg(F.min('B').alias('min_b'),
     F.max('B').alias('max_b'),
     F.avg('C').alias('avg_c')).show()
```

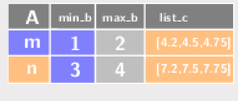


```
def quant_pd(val_list):
   quant = np.round(np.percentile(val_list,[20,50,75]),2)
   return list(map(float,quant))
Fn = F.udf(quant_pd,ArrayType(FloatType()))

df.groupBy(['A']).agg(F.min('B').alias('min_b'),
F.max('B').alias('max_b'),
Fn(F.collect_list(col('C'))).alias('list_c') )
```

Daten bearbeiten

Neue Variablen erzeugen

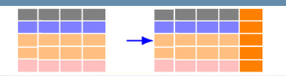

```
df.withColumn('new',1/df.col)
df.withColumn('new',F.log(df.col))
df.withColumn("new", Fn('col'))
```

Teilmengen (Zeilen)

df.na.drop()	Zeilen mit **null** auslassen
df.filter()	Zeilen filtern
df.distinct()	Verschiedene Zeilen extrahieren
df.sample()	Zeilen sampeln

Teilmengen (Spalten)

df.select()	Bilde mit dem Ausdruck ein neues Dataframe

Daten zusammenfassen

df.describe()	Berechnet einfache Statistiken
Correlation.corr(df)	Korrelationskoeffizientenmatrix
df.count()	Zählt die Zeilen

Variablen umbenennen

df.withColumnRenamed()	Spaltennamen ändern